

CT论文思路详解

Stage 1: 态势感知与非平稳性解耦 (Offline)

- 基于 GMM-HMM 的离在线双轨态势解耦模块

三个组件

- 观测变量 (Observation Sequence) O_t :** 这就是你图里画的“多源历史数据”输入。在 t 时刻，它是一个向量 $O_t = [p_t, l_t, w_t, \dots]^T$ ，代表当前的电价、负荷、气象等特征。
- 隐状态变量 (Hidden State Sequence) S_t :** 这是不可见的、驱动电力系统物理运转的内在逻辑，也就是你所说的“态势”。 $S_t \in \{1, 2, \dots, K\}$ 。比如 $S_t = 1$ 代表平稳期， $S_t = 2$ 代表高波动期。
- 模型参数 $\lambda = (\pi, A, B)$:**
 - π : 初始状态概率分布。
 - A : 状态转移概率矩阵 (Transition Matrix)。即从“平稳期”突变到“异常尖峰期”的概率 $P(S_t = j | S_{t-1} = i)$ 。
 - B : 发射概率矩阵 (Emission Matrix)。即在已知当前是“高波动期”的前提下，观测到特定电价和负荷组合的概率 $P(O_t | S_t = j)$ 。由于你的观测变量 O_t 是连续时间序列，这里大概率需要用到高斯混合隐马尔可夫模型 (GMM-HMM)，而不是离散的 HMM。

具体情况

1. 离线阶段 (Offline - 面向历史数据划分):

- 输入:** 包含电价、负荷、气象等多源历史时间序列观测集 $O_{1:T}$ 。
- 核心动作:**
 - 利用 EM 算法 (Baum-Welch) 在全局历史数据上训练 GMM-HMM 模型，求解最优参数 $\lambda = (\pi, A, B)$ 。这确立了电力市场状态转移的物理规律 (转移矩阵 A) 和各个态势下的数据分布 (发射概率 B)。
 - 利用 Viterbi 算法对 $O_{1:T}$ 进行全局最大后验路径解码，为历史序列的每一个时刻 t 打上确定的态势标签 $S_t \in \{1, \dots, K\}$ 。
- 输出:** 将长期的、非平稳的历史数据，严格在时间维度上切分为 K 个具有不同统计特征的数据子集。这些子集将直接喂给 Stage 2 进行独立的动态因果发现。

2. 在线阶段 (Online - 面向实时预测路由):

- 输入:** 实时流式特征数据 X_t (即当前时刻观测值 O_t) 以及离线训练好的参数 $\lambda = (\pi, A, B)$ 。
- 核心动作:** 摒弃全局 Viterbi 算法，启动 前向滤波算法 (Forward Filtering)。利用递推公式 $\alpha_t(j) = b_j(O_t) \left[\sum_{i=1}^K \alpha_{t-1}(i) a_{ij} \right]$ ，实时计算当前系统处于各个态势 k 的后验概率 $P(S_t = k | O_{1:t})$ 。
- 输出:** 执行 Hard Selection，输出当前概率最大的态势索引 k 。这个 k 将作为一个路由信号，直接指示 Stage 3 从库中调取第 k 个因果邻接矩阵作为当前时刻的 Causal Mask。

关于隐藏状态数量K的选择

数据驱动 (模型选择准则): 你可以分别训练 $K = 2, 3, \dots$ 的 HMM 模型，然后计算它们的 AIC (赤池信息准则) 或 BIC (贝叶斯信息准则)。选择 AIC/BIC 值最小的那个 K ，这就是在数学上最平衡了“拟合优度”和“模型复杂度”的态势数量。这也是在论文中非常严谨的论述方式。

Stage 2: 动态因果拓扑挖掘 (Offline)

1. 模块输入 (Input):

- 由 Stage 1 (基于全局历史数据的 Viterbi 解码) 切分出的 K 个具有不同统计特征的时间序列数据子集。假设变量总数为 N (包含电价、负荷、温度等)。

2. 核心执行步骤 (Core Actions): 为了摒弃“静态相关性”，寻找真正的“动态因果性”，该阶段在 K 个数据子集上，分别独立运行 PCMC1 算法。具体物理计算流程分为四步:

- **Step 2.1 - 独立遍历:** 针对每一个态势 $k \in \{1, \dots, K\}$ 的数据子集，单独建立因果推断图模型。
- **Step 2.2 - PC 阶段 (混淆因子剥离):** 进行严密的条件独立性检验。剥离由于“共同混淆因子”（如极端天气同时导致负荷上升和电价上升）而产生的“伪因果边”。
- **Step 2.3 - MCI 阶段 (自相关性克制):** 针对时间序列数据，将变量自身的历史滞后项加入条件集进行二次过滤，消除由于时间序列高自相关性带来的大量“假阳性”连接。
- **Step 2.4 - 掩码矩阵生成 (Binarization):** 将算法输出的因果图结构，转化为严格的邻接矩阵。存在因果关系的边设为 1，被剔除的伪相关边设为 0。

3. 模块输出 (Output) 与物理意义:

- **输出:** 最终输出 K 个不同的因果邻接矩阵 (Causal Adjacency Matrices)。
- **物理意义:** 这构成了你在多态势下的先验知识库。它在数学上证明了你的核心假设：即电力市场中，变量间的驱动逻辑是动态变化的。例如，在“平稳期”掩码矩阵中，气温指向电价的值可能为 0（影响不大）；但在“异常期”掩码矩阵中，气温骤降指向电价尖峰的值被严酷地判定为 1（核心因果驱动力）。

stage 3

1. 模块输入 (Input):

- **数据流 (Data Flow):** 当前时刻 t 的实时多维特征序列 X_t （包含最新的电价、负荷、气象等观测值）。
- **控制流 (Control Flow):** Stage 1 在线计算传递过来的当前态势标签 k ，以及系统据此从 Stage 2 知识库中调取的、与该态势严格对应的第 k 个因果邻接矩阵 A_k 。

2. 核心执行步骤 (Core Actions): 传统的 Self-Attention 机制会计算所有变量之间的注意力权重，极易拟合到噪声。本阶段通过物理掩码的强制注入，重塑神经网络的特征提取逻辑。

- **Step 3.1 - 变量级标识化 (Variable-centric Tokenization):** 采用 iTransformer 的基础架构，将不同物理变量（如“负荷序列”、“温度序列”）分别映射为独立的 Tokens，而不是按照时间步来切分。
- **Step 3.2 - 掩码矩阵极值化 (Mask Initialization):** 将 Stage 2 传入的由 0 和 1 组成的因果矩阵 A_k 转化为注意力掩码。具体操作为：因果边对应位置设为 $-\infty$ ，非因果边（被 PCMCI 斩断的伪相关边）对应位置设为 0。
- **Step 3.3 - 因果注意力物理干预 (Causal Mask Injection):** 在多头注意力机制 (Multi-Head Attention) 进行 Softmax 归一化计算之前，强制注入极值化掩码。数学表达为： $\text{Attn}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + \text{Mask}\right)V$ 。这一步从算法底层屏蔽了非因果连接的权重分配。
- **Step 3.4 - 隐层解码与输出 (Decoding):** 经过因果关系净化后的特征表示，通过前馈神经网络 (FFN) 与解码器，完成时序的非线性映射。

3. 模块输出 (Output) 与物理意义:

- **输出:** 当前时刻的初步点预测结果 $\hat{x}_t$ (Point Forecasts)，以及模型提取的隐层因果特征 (Hidden Features)。
- **物理意义:** 彻底打破了传统 Transformer “万物皆可 Attention” 的黑盒过度拟合问题。该模块迫使深度学习模型严格按照电力市场当前态势下的真实物理/经济因果拓扑图进行信息传递，极大提升了模型在极端天气或突发事件下的抗干扰能力和可解释性。

stage 4: 具备统计保证的区间预测 (Online)

1. 模块输入 (Input):

- **基础输入:** Stage 3 (Causal-iTransformer) 输出的当前时刻 t 的点预测结果（隐层特征及具体的预测数值 $\hat{x}_t$ ）。
- **状态路由信号:** Stage 1 在线前向滤波算法输出的当前确定的态势标签 k （如“高波动期”）。
- **离线数据支持:** 预留的独立校准集 (Calibration Set)。

2. 核心执行步骤 (Core Actions): 为了将单一点预测转化为具有统计学意义的预测区间，该阶段执行动态共形预测。具体分为四步：

- **Step 4.1 - 态势感知过滤 (Regime-Aware Filtering):** 摒弃全局同质化的假设。根据当前时刻的态势标签 k ，从庞大的全局校准集中，动态过滤出仅属于态势 k 的历史样本子集。

- **Step 4.2 - 非一致性分数计算 (Non-conformity Score Calculation):** 在上述过滤出的同质化校准子集上，计算模型预测值与真实值之间的残差（即非一致性分数，例如绝对误差 $e_i = |y_i - \hat{y}_i|$ ）。
- **Step 4.3 - 经验分位数提取 (Empirical Quantile Extraction):** 根据设定的统计置信度目标（如 **95%** 的覆盖率），在计算出的误差分数集合中寻找对应的经验分位数，确定该态势下的误差边界。
- **Step 4.4 - 实时区间生成 (Online Interval Generation):** 将提取出的误差边界直接加減到 Stage 3 输出的实时点预测值 $\hat{y}_t$ 上，生成最终的预测区间。

3. 模块输出 (Output) 与物理意义:

- **输出:** 带有明确覆盖率保证（如 95% Coverage）的最终预测区间。
- **物理意义:** 传统的区间预测宽度是死板的。而你的 Causal-CQR 实现了“预测区间的自适应呼吸”。当 Stage 1 判定当前为“平稳期”时，调用的校准子集误差小，输出的区间极窄，指导精确调度；当判定为“异常尖峰期”时，调用的校准子集误差大，输出的区间自动大幅扩张，为电网提供充分的风险冗余和物理兜底。